3B BT Görüntülerinden Türkçe Radyoloji Rapor Üretimi için Çok Kipli Büyük Dil Modelleri
Multimodal Large Language Models for Turkish Radiology Report Generation from 3D CT Images

Yazarlar Gizlenmiştir

***Özetçe* —Radyoloji raporlarının yazımı, klinisyenler üzerinde önemli bir iş yükü oluşturmaktadır. Tıbbi görüntülerden otomatik rapor üretimine yönelik yapay zeka çalışmaları son yıllarda hız kazanmış olsa da mevcut literatür büyük ölçüde İngilizce'ye odaklanmakta; Türkçe gibi düşük kaynaklı klinik diller için sistematik değerlendirmeler oldukça sınırlı kalmaktadır. Bu çalışmada, üç boyutlu Bilgisayarlı Tomografi (BT) hacimlerinden otomatik Türkçe radyoloji raporu üretimi için çok kipli büyük dil modelleri kapsamlı biçimde karşılaştırılmaktadır. Genel amaçlı (Gemma 3) ve tıbbi alana özgü (MedGemma) modeller; kesit tabanlı ve hacimsel temsil yaklaşımları ile sıfır-örnekli ve parametre verimli ince ayar (QLoRA) senaryoları altında ROUGE ve BERTurk tabanlı BERTScore metrikleriyle değerlendirilmiştir. Sonuçlar, ince ayarın düşük kaynaklı dillerde belirleyici bir rol oynadığını ve kesit tabanlı temsillerin mevcut durumda hacimsel yaklaşımlara kıyasla daha etkili olduğunu ortaya koymaktadır.**

Anahtar Kelimeler—Türkçe Radyoloji Rapor Üretimi, Çok Kipli Büyük Dil Modelleri, İnce Ayar.

***Abstract*—Writing radiology reports constitutes a significant clinical burden for radiologists. While artificial intelligence research on automatic report generation from medical images has gained momentum in recent years, the existing literature predominantly focuses on English, leaving low-resource clinical languages such as Turkish largely underexplored. In this study, multimodal large language models are comprehensively compared for automatic Turkish radiology report generation from three-dimensional Computed Tomography (CT) volumes. General-purpose (Gemma 3) and medical domain-specific (MedGemma) models are evaluated under slice-based and volumetric representation strategies, as well as zero-shot and parameter-efficient fine-tuning (QLoRA) scenarios, using ROUGE and BERTurk-based BERTScore metrics. Results demonstrate that fine-tuning plays a decisive role in low-resource languages and that slice-based representations outperform volumetric approaches in the current setup.**

Keywords—Turkish Radiology Report Generation, Multimodal Large Language Models, Fine-Tuning.

I. GİRİŞ

Radyoloji raporları, tıbbi görüntüleme bulgularının klinik karar süreçlerine aktarılmasında kritik bir işlev üstlenmektedir. Ancak rapor yazımı, zaman alıcı yapısı nedeniyle radyologların günlük iş yükünün önemli bir bölümünü oluşturmaktadır. Bu soruna çözüm arayışıyla birlikte tıbbi görüntülerden otomatik rapor üretimi, son yıllarda klinik karar destek sistemleri araştırmalarının öncelikli konularından biri haline gelmiştir [1]–[3].

Erken dönem çalışmalar, görüntü özelliklerinin çıkarılması ve bu özelliklerin tekrarlayan sinir ağları aracılığıyla metne dönüştürülmesine dayanmaktadır. Örneğin Jing ve arkadaşları [4], etiket tahmini ile paragraf üretimini birlikte ele alan çok görevli bir mimari önermiş; uzun raporların oluşturulması için hiyerarşik LSTM tabanlı bir model geliştirmiştir. Günümüzde ise çok kipli görme-dil modelleri ve büyük dil modelleri bu alanda önemli ilerlemeler sağlamıştır [5]. Bu modeller, görsel temsilleri ve doğal dil üretimini ortak bir mimari çatısı altında birleştirerek tıbbi görüntülerden rapor üretimi gibi karmaşık görevleri başarıyla ele almaktadır.

Bununla birlikte, mevcut çalışmaların büyük bölümü İngilizce radyoloji raporları üzerine yoğunlaşmaktadır. Türkçe gibi görece düşük kaynaklı klinik diller için hem veri kümeleri hem de sistematik model karşılaştırmaları oldukça sınırlıdır. Öte yandan, bilgisayarlı tomografi (BT) gibi üç boyutlu tıbbi görüntüleme verilerinin çok kipli dil modelleriyle nasıl etkin biçimde bütünleştirileceği henüz tam anlamıyla yanıtlanmamış bir araştırma sorusudur. Özellikle kesit tabanlı ve hacimsel temsil yaklaşımları arasındaki farkın rapor üretim performansına etkisi yeterince incelenmemiştir. Literatür taraması kapsamında, üç boyutlu BT verilerinden otomatik Türkçe radyoloji raporu üretimini ele alan ve farklı modelleme stratejilerini sistematik biçimde karşılaştıran bir çalışmaya rastlanmamıştır.

Bu çalışmada, üç boyutlu BT hacimlerinden otomatik Türkçe radyoloji raporu üretimi için farklı modelleme stratejileri karşılaştırmalı olarak incelenmektedir. Bu kapsamda, kesit tabanlı görsel temsiller ile hacimsel kodlayıcılar kullanılarak elde edilen temsiller, genel amaçlı ve tıbbi alana özgü çok kipli büyük dil modelleri üzerinde değerlendirilmektedir. Ayrıca sıfır-örnekli kullanım ile parametre verimli ince ayar yaklaşımları aynı deneysel protokol altında karşılaştırılmaktadır. Literatür incelemesi kapsamında, üç boyutlu BT hacimlerinden otomatik Türkçe radyoloji raporu üretimini ele alan ve farklı modelleme stratejilerini sistematik biçimde karşılaştıran bir çalışmaya rastlanmamıştır. Bu yönüyle çalışma, düşük kaynaklı

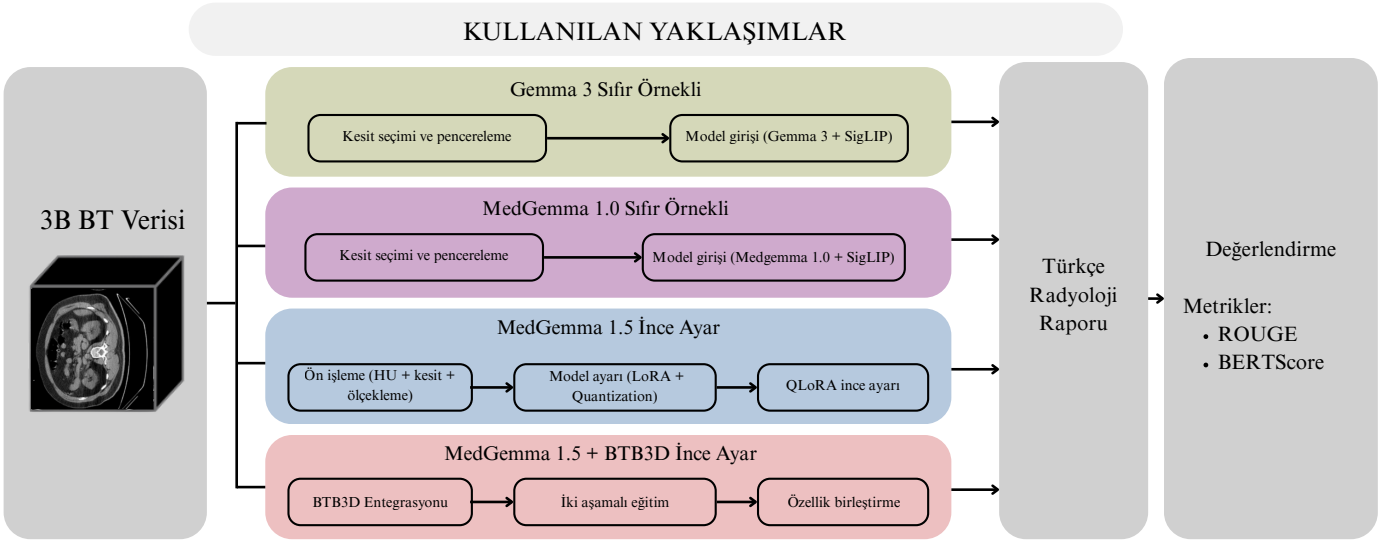

Şekil 1: **Üç boyutlu BT hacimlerinden Türkçe radyoloji raporu üretimi için önerilen deneysel çerçeve.** Kesit tabanlı ve hacimsel temsil yaklaşımları; sıfır-örnekli (Gemma 3, MedGemma 1.0) ve parametre verimli ince ayar (MedGemma 1.5, MedGemma 1.5+BTB3D) senaryoları altında karşılaştırmalı olarak değerlendirilmektedir.

bir klinik dilde çok kipli büyük dil modellerinin davranışını analiz eden ilk kapsamlı karşılaştırmalı çalışma olma özelliği taşımaktadır.

Bu çalışmanın başlıca katkıları şu şekilde özetlenebilir:

1) Türkçe radyoloji rapor üretimi için çok modlu büyük dil modellerinin kapsamlı ve sistematik bir karşılaştırması sunulmaktadır.
2) Kesit tabanlı ve hacimsel temsil yaklaşımlarının rapor üretim performansı üzerindeki etkisi deneysel olarak ortaya konmaktadır.
3) Sıfır-örnekli kullanım ile parametre verimli ince ayar yaklaşımlarının karşılaştırılmasıyla model davranışına ilişkin somut bulgular elde edilmektedir.

II. Yöntem

Bu çalışmada, üç boyutlu BT hacimlerinden Türkçe radyoloji raporu üretimi problemi iki temel eksen üzerinden incelenmektedir: (i) kesit tabanlı ve hacimsel temsil yaklaşımları, (ii) sıfır-örnekli kullanım ve ince ayar stratejileri. Bu doğrultuda dört farklı yöntem değerlendirilmiştir: (i) *Gemma 3* sıfır-örnekli kullanım, (ii) *MedGemma 1.0* sıfır-örnekli kullanım, (iii) *MedGemma 1.5* ince ayar ve (iv) *BTB3D* ile zenginleştirilmiş *MedGemma 1.5* ince ayar. Tüm yöntemlerin genel akışı Şekil 1'de gösterilmektedir.

A. Veri Kümesi

Deneylerde 3B BT hacimleri ile eşleşen radyoloji raporlarını içeren CT-RATE veri kümesi kullanılmıştır [6]. Veri kümesinin kamuya açık sürümü yalnızca İngilizce raporlar içermektedir; bu çalışmada ise veri kümesi geliştiricilerinden alınan özel izin kapsamında elde edilen Türkçe raporlardan yararlanılmıştır. Hesaplama maliyetini makul düzeyde tutmak amacıyla veri kümesinden rastgele örnekleme yoluyla seçilen 10.000 eğitim ve 2.000 test örneği kullanılmıştır.

B. Sıfır-Örnekli Yaklaşımlar

1) Gemma 3: Genel amaçlı çok kipli büyük dil modeli olan *Gemma 3* (4B) [7], görsel girdileri *SigLIP* [8] görüntü kodlayıcısı aracılığıyla işleyebilmektedir. Üç boyutlu BT hacimleri modele doğrudan girdi olarak verilemediğinden, literatürde yaygın biçimde benimsenen kesit tabanlı temsil yaklaşımı tercih edilmiştir. Bu kapsamda hacmin orta bölümünden üç kesit seçilmiştir. Farklı doku yapılarını aynı anda temsil edebilmek amacıyla kemik/akciğer (2250, -100), yumuşak doku (350, 40) ve beyin (80, 40) olmak üzere üç farklı pencereleme ayarı uygulanmış; elde edilen görüntüler RGB kanallarına yerleştirilerek çok kanallı bir görsel temsil oluşturulmuştur.

2) MedGemma 1.0: Gemma mimarisi üzerine inşa edilmiş olan *MedGemma 1.0* [9], tıbbi verilerle sürdürülen ön eğitim sayesinde klinik terminoloji ve tıbbi akıl yürütme açısından genel amaçlı modele kıyasla daha uzmanlaşmış bir yapıya sahiptir. Ancak model, üç boyutlu hacimleri doğrudan işleyemediğinden Gemma 3 ile aynı kesit tabanlı giriş hazırlama protokolü bu model için de uygulanmıştır.

C. İnce Ayar Yaklaşımları

1) MedGemma 1.5: MedGemma 1.5 modeli [9], parametre verimli ince ayar yöntemi kullanılarak Türkçe radyoloji raporu üretimi görevine uyarlanmıştır. Eğitim sürecinde GPU bellek kullanımını sınırlamak amacıyla LoRA tabanlı ince ayar [10] ve 4-bit nicemleme birlikte uygulanmıştır. Modele daha zengin bir hacimsel bağlam sunabilmek için hacmin orta bölümünden 16 kesit seçilmiş; kesit yoğunluk değerleri yeniden ölçekleme parametreleriyle normalize edilmiştir. Tutarlı bir uzamsal temsil elde etmek amacıyla hacim verisi eksen düzeni yeniden düzenlenmiştir. Her kesit, farklı doku aralıklarını eş zamanlı olarak temsil edebilmek için üç farklı pencereleme uygulanarak RGB görüntülerine dönüştürülmüş ve 384×384 çözünürlüğe ölçeklendirilmiştir.

TABLO I: MedGemma 1.5 ince ayar eğitim yapılandırması

Parametre	Değer
LoRA rank (r)	16
LoRA alpha (α)	32
Dropout	0.05
Bias	none
Görev türü	CAUSAL_LM
Hedef modüller	q_proj, k_proj, v_proj, o_proj gate_proj, up_proj, down_proj
Nicemleme	4-bit
Cihaz başına batch büyüklüğü	2
Gradient accumulation	4
Efektif batch büyüklüğü	8
Öğrenme oranı	2×10^{-4}

TABLO II: BTB3D + MedGemma 1.5 eğitim yapılandırması

Parametre	Değer
LoRA rank (r)	16
LoRA alpha (α)	32
Dropout	0.05
Hedef modüller	q_proj, k_proj, v_proj, o_proj
Projeksiyon öğrenme oranı	5×10^{-5}
LoRA öğrenme oranı	2×10^{-5}
Etkin yığın boyutu	16 (gradyan birikimi)
Nicemleme	4-bit (QLoRA)
Eğitim örneği	10,000

Eğitim sırasında öğretmen zorlama (*teacher forcing*) stratejisi benimsenmiş; kayıp yalnızca hedef rapor belirteçleri üzerinden hesaplanmıştır. Eğitim yapılandırmasına ilişkin ayrıntılar Tablo I'de sunulmaktadır.

2) BTB3D+MedGemma 1.5: Kesit tabanlı yaklaşımların aksine, *BTB3D* [11] hacimsel kodlayıcısı tüm BT hacmini doğrudan işleyerek dilimler arası anatomik ilişkileri koruyan temsiller üretmektedir. Bu sayede iki boyutlu kodlayıcılarda kaybolabilecek uzamsal bağlam bilgisi korunmaktadır. BT hacimleri normalizasyon ve yeniden örnekleme işlemlerinden geçirildikten sonra BTB3D kodlayıcı ile temsil edilmiştir. Elde edilen özellik vektörleri, çok katmanlı perseptron tabanlı bir izdüşüm modülü aracılığıyla MedGemma gömme uzayına eşlenmiştir. Bellek kısıtlarını azaltmak amacıyla uzamsal ortalama havuzlama uygulanmış; görsel belirteçler metin belirteçleri ile birleştirilerek modele verilmiştir.

Eğitim iki aşamada gerçekleştirilmiştir. İlk aşamada yalnızca izdüşüm modülü eğitilerek görsel temsiller dil modeli gömme uzayı ile hizalanmıştır. İkinci aşamada ise izdüşüm modülü ve LoRA adaptörleri birlikte eğitilerek modelin rapor üretim performansı artırılmıştır. Kayıp fonksiyonu olarak standart çapraz entropi kullanılmış; kayıp hesaplaması yalnızca asistan yanıtı belirteçleri (bulgular ve izlenim) üzerinden gerçekleştirilmiş, görsel belirteçler ve sistem istemi belirteçleri ise maskelenmiştir. Eğitim yapılandırmasına ilişkin ayrıntılar Tablo II'te verilmiştir.

III. Bulgular ve Tartışma

Bu çalışmada model çıktılarının kalitesini değerlendirmek amacıyla ROUGE [12] ve BERTScore [13] metrikleri kullanılmıştır. ROUGE metrikleri n-gram örtüşmesine dayalı olarak metinler arasındaki yüzeysel benzerliği ölçerken, BERTScore bağlamsal gömüler üzerinden anlamsal benzerliği değerlendirmektedir. Türkçe metinler için BERTScore hesaplamasında BERTurk [14] modeli kullanılmıştır.

TABLO III: Türkçe radyoloji rapor üretiminde kullanılan modellerin performans sonuçları

Model	R-1	R-2	R-L	BS-P	BS-R	BS-F1
Gemma 3 (Sıfır Örnekli)	0.21	0.05	0.11	0.59	0.53	0.55
MedGemma (Sıfır Örnekli)	0.18	0.05	0.10	0.61	0.46	0.53
MedGemma 1.5 (İnce Ayar)	0.43	0.24	0.26	0.64	0.70	0.66
MedGemma 1.5 + BTB3D	0.30	0.15	0.17	0.63	0.64	0.63

MedGemma 1.5 modeli ile gerçekleştirilen sıfır-örnekli deneylerde modelin çıktılarının ağırlıklı olarak İngilizce üretilmesi nedeniyle bu sonuçlar değerlendirme kapsamına dahil edilmemiştir. Bu durum, çok modlu büyük dil modellerinin düşük kaynaklı dillerde doğrudan kullanımının sınırlı olduğunu ve dil uyumunun kritik bir faktör olduğunu açıkça ortaya koymaktadır.

Tablo III'da sunulan sonuçlar üç temel karşılaştırma ekseni üzerinden değerlendirilebilmetedir.

İlk olarak, sıfır-örnekli ve ince ayar yaklaşımları arasında belirgin bir performans farkı bulunmaktadır. MedGemma 1.5 modelinin ince ayar sonrasında tüm metriklerde önemli bir artış sağladığı ve en yüksek performansa ulaştığı görülmektedir (ROUGE-L: 0.26, BERTScore-F1: 0.66). Bu bulgu, düşük kaynaklı dillerde yüksek kaliteli rapor üretimi için ince ayarın kritik bir bileşen olduğunu açıkça göstermektedir.

İkinci olarak, genel amaçlı ve tıbbi alana özgü modeller karşılaştırıldığında, Gemma 3 modelinin sıfır-örnekli senaryoda MedGemma modelinden daha iyi performans gösterdiği gözlemlenmektedir. Bu durum, genel amaçlı modellerin daha geniş dil kapsamına sahip olması nedeniyle Türkçe üretimde avantaj sağladığını göstermektedir. Buna karşılık, tıbbi alana özgü modellerin dil uyumu açısından ince ayar olmadan dezavantajlı kalabildiği görülmektedir.

Üçüncü olarak, BTB3D ile zenginleştirilen modelin performansının, ince ayar yapılmış MedGemma 1.5 modelinin gerisinde kalması dikkat çekicidir. Bu durum, hacimsel temsillerin teorik avantajlarına rağmen pratikte dil modeli ile etkin biçimde hizalanmasının zor olduğunu göstermektedir. Özellikle BTB3D çıktılarının yüksek sayıda görsel belirteç üretmesi, bu belirteçlerin sınırlı veri rejiminde dil modeli gömme uzayı ile yeterince hizalanamamasına yol açmaktadır. Ayrıca projeksiyon modülünün kapasitesi ve iki aşamalı eğitim sürecinin sınırlı veri ile gerçekleştirilmesi, hacimsel bilginin metin üretimine etkin şekilde aktarılmasını zorlaştırmaktadır. Bu bulgu, hacimsel temsil kullanımının tek başına performans artışı garantilemediğini, temsil ve dil modeli arasındaki etkileşimin kritik bir bileşen olduğunu ortaya koymaktadır.

Şekil 2 incelendiğinde, ince ayar yapılmış MedGemma 1.5 modelinin gerçek rapor ile yüksek düzeyde uyumlu çıktılar ürettiği görülmektedir. Buna karşılık, BTB3D ile zenginleştirilen model bazı bulguları doğru şekilde yakalayabilse de kritik bilgilerin bir kısmını eksik veya hatalı üretmektedir. Sıfır-örnekli modellerin çıktıları ise çoğunlukla alakasız veya hatalı ifadeler içermektedir. Bu nitel gözlemler, nicel sonuçlarla tutarlı olup ince ayar yapılmış MedGemma 1.5 modelinin en başarılı yaklaşım olduğunu desteklemektedir.

Deneysel analizler, modellerin yalnızca metin benzerliği açısından değil, klinik doğruluk açısından da farklı davranışlar sergilediğini göstermektedir. Özellikle sıfır-örnekli yaklaşım-

Şekil 2: Model çıktılarının gerçek rapor ile nitel karşılaştırması. Solda giriş görüntüsü ve modele verilen komut, sağda ise gerçek rapor ve farklı modellerin ürettiği raporlar gösterilmektedir. Doğru bulgular yeşil, hatalı bulgular kırmızı ile işaretlenmiş belirsiz veya alakasız ifadeler işaretlenmemiştir.

larda, görüntü ile desteklenmeyen bulguların üretilmesi (halüsinasyon) ve önemli bulguların atlanması sık gözlemlenmiştir. Buna karşılık ince ayar yapılan MedGemma 1.5 modeli, hem doğru bulguları yakalama hem de klinik olarak tutarlı rapor üretme açısından daha güvenilir sonuçlar üretmiştir.

IV. Sonuç

Bu çalışmada, üç boyutlu BT hacimlerinden Türkçe radyoloji raporu üretimi için farklı çok modlu büyük dil modeli tabanlı yaklaşımlar karşılaştırılmıştır. Elde edilen bulgular üç temel sonucu ortaya koymaktadır. İlk olarak, parametre verimli ince ayar yöntemleri sıfır-örnekli kullanıma kıyasla belirgin performans artışı sağlamaktadır. İkinci olarak, genel amaçlı modellerin sıfır-örnekli senaryoda daha geniş dil kapsamı sayesinde daha iyi sonuçlar verebildiği gözlemlenmiştir. Üçüncü olarak, hacimsel temsillerin her durumda performans avantajı sağlamadığı ve kesit tabanlı yaklaşımların ince ayar ile birlikte daha güçlü sonuçlar üretebildiği görülmüştür. Bu bulgular, düşük kaynaklı dillerde model performansını belirleyen temel faktörlerin dil uyumu, ince ayar stratejisi ve görsel temsil biçimi olduğunu göstermektedir. Gelecek çalışmalarda, hacimsel temsiller ile dil modelleri arasındaki hizalamanın geliştirilmesi ve model güvenilirliğini artırmaya yönelik öğrenme stratejilerinin incelenmesi planlanmaktadır.

Kaynaklar

[1] S. Maity and M. J. Saikia, "Large language models in healthcare and medical applications: a review," *Bioengineering*, vol. 12, no. 6, p. 631, 2025.

[2] E. Yu, X. Chu, W. Zhang, X. Meng, Y. Yang, X. Ji, and C. Wu, "Large language models in medicine: applications, challenges, and future directions," *International Journal of Medical Sciences*, vol. 22, no. 11, p. 2792, 2025.

[3] X. Meng, X. Yan, K. Zhang, D. Liu, X. Cui, Y. Yang, M. Zhang, C. Cao, J. Wang, X. Wang *et al.*, "The application of large language models in medicine: A scoping review," *Iscience*, vol. 27, no. 5, 2024.

[4] B. Jing, P. Xie, and E. Xing, "On the automatic generation of medical imaging reports," in *EMNLP*, 2018.

[5] X. Li, L. Li, Y. Jiang, H. Wang, X. Qiao, T. Feng, H. Luo, and Y. Zhao, "Vision-language models in medical image analysis: From simple fusion to general large models," *Information Fusion*, vol. 118, p. 102995, 2025.

[6] I. E. Hamamci *et al.*, "Generalist foundation models from a multimodal dataset for 3d computed tomography," *Nature Biomedical Engineering*, Feb. 2026.

[7] Gemma Team *et al.*, "Gemma 3 technical report," *arXiv preprint arXiv:2503.19786*, 2025.

[8] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid loss for language image pre-training," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2023, pp. 11 975–11 986.

[9] A. Sellergren, S. Kazemzadeh, T. Jaroensri, A. Kiraly, M. Traverse, T. Kohlberger, S. Xu, F. Jamil, C. Hughes, C. Lau *et al.*, "Medgemma technical report," *arXiv preprint arXiv:2507.05201*, 2025.

[10] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "Lora: Low-rank adaptation of large language models," *arXiv preprint arXiv:2106.09685*, 2021.

[11] I. E. Hamamci, S. Er, S. Shit, H. Reynaud, D. Yang, P. Guo, M. Edgar, D. Xu, B. Kainz, and B. Menze, "Better tokens for better 3d: Advancing vision-language modeling in 3d medical imaging," *arXiv preprint arXiv:2510.20639*, 2025.

[12] C.-Y. Lin, "Rouge: A package for automatic evaluation of summaries," in *Text summarization branches out*, 2004, pp. 74–81.

[13] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, "Bertscore: Evaluating text generation with bert," *arXiv preprint arXiv:1904.09675*, 2019.

[14] S. Schweter, "Berturk - bert models for turkish," Apr. 2020. [Online]. Available: https://doi.org/10.5281/zenodo.3770924